

# AGENTE AUTÔNOMO PARA ANÁLISE DE EDITAIS DE LICITAÇÃO

---

Entrega 2 - Relatório final de implementação e avaliação

MVP RAG com evidências, benchmark humano e avaliação RAGAS

Danielle Magalhães Ballester  
Carol Anely Miranda Guzman  
André Joás Lima de Araújo  
David Damasceno da Frota  
Raylson Silva de Lima

22 de julho de 2026

## Resumo executivo

Foi concluído um MVP para extração rastreável de informações críticas de editais, com Flask, PyMuPDF, OCR, embeddings MiniLM, FAISS, respostas estruturadas, evidências literais e um FunctionAgent real do LlamaIndex.

O benchmark contém 10 editais e 30 referências humanas validadas. Foram executadas 12 configurações RAG no desenvolvimento, com seleção exclusiva nesse split. O teste final foi aberto somente depois do congelamento por hash.

**Resultado principal: Faithfulness 1.00, Answer Correctness 0.8469 e alucinação 50%. A hipótese foi parcialmente confirmada.**

A cobertura do RAG foi 2/9 campos. Essa limitação é central: as médias RAGAS descrevem somente as respostas existentes e não compensam os sete campos sem resposta.

## Equipe e responsabilidades

| Integrante                   | Papel                                  | Contribuição consolidada          |
|------------------------------|----------------------------------------|-----------------------------------|
| Danielle Magalhães Ballester | Liderança, documentação e apresentação | Coordenação e narrativa           |
| Carol Anely Miranda Guzman   | Dados                                  | Organização e qualidade dos dados |
| André Joás Lima de Araújo    | Engenharia e modelagem                 | Pipeline, indexação e agente      |
| David Damasceno da Frota     | Avaliação                              | Benchmark, métricas e erros       |
| Raylson Silva de Lima        | Reprodutibilidade                      | Ambiente, testes e execução       |

# 1. Problema, hipótese e objetivos

Editais são longos, heterogêneos e distribuem informações críticas entre texto principal e anexos. A análise manual é custosa e sujeita a falhas; LLMs sem fonte podem alucinar. O projeto investiga se RAG consegue combinar extração estruturada e rastreabilidade.

## Pergunta de pesquisa

Em que medida um agente baseado em RAG consegue extrair prazo, valor estimado e modalidade com Faithfulness >= 0,85, Answer Correctness >= 0,80 e alucinação <= 10%?

## Hipótese

Os três limiares seriam alcançados no conjunto de teste.

## Objetivos realizados

- Pipeline PDF/OCR, chunking, embeddings e FAISS.
- Extração estruturada com evidência literal e página.
- Benchmark humano com desenvolvimento/teste isolados.
- Comparação com regex e LLM sem recuperação.
- Métricas RAGAS, custo, tokens, latência, gráficos e análise de erros.
- FunctionAgent real e conector opcional para a API pública do PNCP.

# 2. Arquitetura e implementação

## Fluxo técnico

PDF -> validação -> extração PyMuPDF/OCR -> chunking -> embeddings MiniLM -> FAISS -> recuperação por document\_id -> LLM -> JSON estruturado -> validação de evidência -> aplicação/agent.

| Camada      | Implementação                       | Controle de qualidade              |
|-------------|-------------------------------------|------------------------------------|
| Entrada     | Upload Flask e coleta PNCP opcional | Assinatura PDF, tamanho, SHA-256   |
| Documento   | PyMuPDF e Tesseract                 | Fallback OCR e páginas preservadas |
| Recuperação | MiniLM + FAISS                      | Filtro obrigatório por document_id |
| Geração     | Groq openai/gpt-oss-120b            | Temperatura 0 e JSON estruturado   |
| Evidência   | Página, chunk e trecho              | Validação literal e normalização   |
| Agente      | LlamaIndex FunctionAgent            | Ferramenta tipada e top-k limitado |

O FunctionAgent está disponível na aplicação. O experimento mede diretamente seu núcleo RAG/extrator para evitar chamadas de orquestração diferentes entre configurações.

### 3. Dados e benchmark

| Item                        | Quantidade/estado |
|-----------------------------|-------------------|
| PDFs fornecidos manualmente | 18                |
| PDFs indexados              | 18                |
| Chunks/vetores              | 951               |
| Editais no benchmark        | 10                |
| Desenvolvimento/teste       | 7/3               |
| Referências humanas         | 30/30 validadas   |

Os 18 PDFs foram colocados manualmente pelo usuário. Eles não foram carregados pelo sistema e não recebem proveniência PNCP retroativa.

#### Campos críticos

- Valor estimado.
- Modalidade.
- Prazo de entrega da proposta.

Cada referência contém valor, página, trecho e identificação do revisor. A importação foi transaccional e validou a presença literal da evidência no PDF.

### 4. Protocolo experimental

| Parâmetro                    | Valor                                  |
|------------------------------|----------------------------------------|
| Modelo                       | openai/gpt-oss-120b via Groq free tier |
| Temperatura / reasoning      | 0 / low                                |
| Máximo de saída              | 800 tokens                             |
| Chunks                       | 300, 500 e 800 palavras                |
| Overlaps                     | 50 e 80 palavras                       |
| Top-k                        | 3 e 5                                  |
| Configurações RAG            | 12                                     |
| Baselines                    | Regex e LLM sem recuperação            |
| Linhas desenvolvimento/teste | 294 / 27                               |


O contexto do juiz RAGAS foi limitado a 12.000 caracteres, priorizando o chunk da evidência e os demais por similaridade. A medida foi necessária para o limite gratuito de 8.000 tokens por minuto e não alterou as respostas geradas.

## 5. Seleção no desenvolvimento

Configuração selecionada: **chunk500\_overlap50\_topk3**. O arquivo registra *source\_split: development* e foi congelado com SHA-256 antes do teste.

Critério hierárquico: Answer Correctness descendente, Faithfulness descendente, alucinação ascendente, custo ascendente e latência ascendente.


A configuração selecionada respondeu apenas 2/21 campos no desenvolvimento. Ambas as respostas tiveram métricas 1,00. A baixa cobertura (9,5%) deixa a escolha sensível ao pequeno n e deve ser tratada como limitação metodológica.




## 6. Resultado final no teste

| Abordagem       | Resp. | Cobertura | Faithfulness | Correctness | Alucinação |
|-----------------|-------|-----------|--------------|-------------|------------|
| Regex           | 3/9   | 33,3%     | 1.0000       | 0.8777      | 66.7%      |
| LLM sem RAG     | 1/9   | 11,1%     | 1.0000       | 1.0000      | 0.0%       |
| RAG selecionado | 2/9   | 22,2%     | 1.0000       | 0.8469      | 50.0%      |

As métricas RAGAS são médias somente sobre campos respondidos: n=3 para regex, n=1 para LLM sem RAG e n=2 para o RAG selecionado.



## Alucinação no teste



O RAG selecionado produziu uma resposta classificada como contraditória entre as duas respostas existentes, resultando em 50%.

## 7. Teste da hipótese

| Meta               | Limiar  | Observado | Resultado    |
|--------------------|---------|-----------|--------------|
| Faithfulness       | >= 0,85 | 1,0000    | Atingida     |
| Answer Correctness | >= 0,80 | 0,8469    | Atingida     |
| Alucinação         | <= 10%  | 50,0%     | Não atingida |

Conclusão: hipótese parcialmente confirmada.

## 8. Análise de erros

A análise classificou **21** casos de campo ausente/não extraído e **3** diferenças de modalidade.

### Erro dominante: cobertura

No RAG selecionado, sete dos nove campos permaneceram sem resposta. Melhorar a recuperação e a extração é mais importante do que otimizar pequenas diferenças entre médias condicionais.

### Normalização de modalidade

A resposta RAG 'LEILÃO ELETRÔNICO, do tipo MAIOR LANCE' foi comparada à referência 'leilão eletrônico'. O conteúdo traz a modalidade correta e um qualificador adicional, mas foi tratado como contradição. A avaliação futura deve separar modalidade, meio eletrônico e critério/tipo.

### Recomendações

- Usar cobertura mínima como gate de seleção.
- Normalizar modalidade por componentes.
- Criar consultas específicas por campo e reforçar recuperação de prazos e valores.
- Ampliar o benchmark e reportar intervalos de confiança.




## 9. Custo e latência


| Etapa           | Tokens de geração | Custo teórico   |
|-----------------|-------------------|-----------------|
| Desenvolvimento | 234.879           | US\$ 0,04427730 |
| Teste           | 10.517            | US\$ 0,00219495 |
| Total           | 245.396           | US\$ 0,04647225 |

O experimento utilizou o plano gratuito. Os valores são equivalentes às tarifas on-demand configuradas, não cobranças observadas. As chamadas internas do RAGAS não expõem uso consolidado e não estão incluídas.

### Custo médio por linha no teste



## Latência média por linha no teste



A regex foi praticamente instantânea, enquanto a geração LLM levou em média 20,64 s e o RAG 24,54 s por linha. O custo adicional do RAG decorre do contexto recuperado.

## 10. PNCP/Compras.gov.br e proveniência

O objetivo de coleta oficial foi tratado com um conector opcional para a API pública do PNCP. O módulo consulta contratações por publicação, lista documentos e baixa PDFs específicos.

| Controle     | Implementação                                     |
|--------------|---------------------------------------------------|
| Origem       | URL oficial e identificadores PNCP                |
| Integridade  | SHA-256                                           |
| Formato      | Assinatura %PDF-                                  |
| Tamanho      | Máximo de 50 MB                                   |
| Proveniência | Data, título, tipo e publicação PNCP              |
| Isolamento   | Downloads não entram automaticamente no benchmark |

A consulta online de fumaça em 22/07/2026 expirou após as retentativas. A integração possui testes simulados, mas a coleta real deve ser repetida quando o endpoint estiver disponível. Não se afirma que os 18 PDFs existentes foram obtidos por API.

## 11. Reprodutibilidade

Ambiente adotado: Python global, conforme decisão do usuário. A suíte final possui 41 testes aprovados.

### Comandos

```
python -m pytest -q tests
python evaluation/run_experiments.py --benchmark evaluation/benchmark.json --split development
python evaluation/run_experiments.py --benchmark evaluation/benchmark.json --split test
python evaluation/generate_reports.py
python scripts/collect_pncp.py search --start 20260701 --end 20260702 --modality 6 --page 1 --uf CE
```

## 12. Limitações

- Teste com 3 documentos e 9 campos.
- Cobertura RAG de 22,2% no teste.
- Seleção favoreceu escores condicionais calculados sobre somente duas respostas.
- Uso interno de tokens do RAGAS não consolidado.
- Contexto do juiz limitado a 12.000 caracteres no plano gratuito.
- Consulta real ao PNCP indisponível no teste online.

## 13. Conclusão

O núcleo técnico, o benchmark humano e a avaliação final foram concluídos. O RAG apresentou alta fidelidade e correção média nas respostas existentes, mas não atingiu a meta de alucinação e respondeu poucos campos. O resultado não confirma integralmente a hipótese.

O próximo ciclo deve priorizar cobertura, normalização e tamanho de amostra. Depois dessas correções, o protocolo pode ser repetido mantendo o mesmo isolamento entre desenvolvimento e teste.

**Status final: hipótese parcialmente confirmada; MVP funcional; evidência experimental concluída com limitações explícitas.**

## Referências e artefatos

- API PNCP: <https://pncp.gov.br/api/consulta/swagger-ui/index.html>
- Manual PNCP: <https://pncp.gov.br/manual/pt-br/latest/singlehtml/index.html>
- RAGAS: <https://docs.ragas.io/>
- LlamaIndex: <https://docs.llamaindex.ai/>
- Resultados: [evaluation/results/](#)
- Gráficos: [docs/figs/](#)